





Masterstudiengang Wirtschaftsinformatik

Big Data Engineering

FH Münster
Master Wirtschaftsinformatik
Wintersemester 2013
Dozent: Lars George

Einheit 6



- Rückblick auf Einheit 5
- Diskussion: BDE Zwischenstand
- Datenpipelines
 - Oozie, Crunch, Cascading, Morphlines
- Hauptziel: Gelernte Techniken kombiniert zur Verarbeitung von Daten einsetzen. Robuste Datenpipelines aufbauen.

• Übung 6:

 Oozie Workflow erstellen und schon bekannte Methoden dort kombinieren

Einheit 6

- Rückblick auf Einheit 5
- Diskussion: BDE Zwischenstand
- Datenpipelines

Rückblick auf Einheit 5



- Fragen?
 - HBase ausprobiert?
 - Andere NoSQL Datenbank ausprobiert?
 - Hush?
- Übung 5: HBase Tabellen?

Einheit 6

- Rückblick auf Einheit 5
- Diskussion: BDE Zwischenstand
- Datenpipelines

BDE Zwischenstand



Eine Frage...

Was ist Big Data Engineering?

BDE Zwischenstand



Wir versuchen nun **zusammenzufassen**, was Big Data Engineering (**BDE**) genau **ist**, nachdem wir **viele** Teile des **Hadoop** Ökosystems angeschaut haben.

Ist BDE nicht das **Gleiche**, wie schon **normale**Datenverarbeitung zuvor? Was **bringt** denn BDE an **zusätzlichen** Vorteilen? Was bringt es für **Nachteile**, oder wo sind die **Schwierigkeiten** verborgen?



BDE ist ein evolutionärer Ansatz, welcher durch Moore's Gesetz erst möglich wurde: Durch die ewig steigende Computerleistung bei gleichbleibenden Kosten, kann man heute kostengünstig riesige Rechnerverbunde aufbauen, welche sich aus einfach wartbaren Komponenten zusammensetzt. Damit kann man Daten speichern – und verarbeiten! – welche in der Vergangenheit ignoriert wurden.



Weiterhin werden diese einfach aufgebauten Systeme auch mit dem Hinblick auf Ausfall konzipiert. Jede Hard- und Softwarekomponente kann leicht ausgetauscht werden.

Bei der Software bedeutet dies, dass Prozesse redundant und hochverfügbar aufgebaut sind, damit niemals ein Service ausfällt und die Leistung sich linear mit dem Umfang des Ausfalls verringert.



Erste Systeme im BDE Umfeld waren reine Batchsysteme, denn diese erlauben es riesige Datenmenge verteilt zu speichern und verarbeiten. Es wurde auf Durchsatz und weniger auf Latenzzeiten geachtet.

Mit dem weiteren Fortschritt der Hard- und Software kann man nun auch interaktive ("Echtzeit") Systeme verwirklichen, welche auf derselben Hardware laufen.



Durch geschickte Nutzung von Prinzipien der verteilten Systeme, wie zum Beispiel Replikation von Daten und der Speicherung in speziellen Dateiformaten, welche dem Anwendungsfall angepasst sind, kann selbst auf großen Datenmengen eine zufriedenstellende Leistung erbracht werden.

BDE ist die Anwendung, aber auch Entwurf und Implementierung solcher Systeme!



Ein **Big Data Engineer** sollte die Merkmale der verteilter Verarbeitung kennen, also die

- Architektur solcher Systeme,
- deren Schnittstellen (nativ oder REST etc.),
- Eigenheiten (Konsistenzgarantie, Transaktionen, Index, Durchsatz, Latenz) und
- Vor- und Nachteile (Datenverlust?).

Damit kann die richtige Entscheidung getroffen werden, für einen gegebenen Anwendungsfall.



Neben der **Auswahl** der Hardware und Softwareplattform, hat BDE aber eine weitere Disziplin, die der Datenverarbeitung selbst. Dazu gehört das **tiefe** Verständnis der Bedeutung der Daten. Hier kommt das Data Science ins Spiel. Es sind aber nicht nur die mathematischen Formeln wichtig, sondern auch wie die Daten vorbereitet werden. Im BDE Umfeld stammen Daten oft **nicht** aus eigenen Quellen und müssen angepasst werden.



Semi- oder unstrukturierte Daten bedeutet meistens nur "nicht mein Schema". Wenn zum Beispiel Twitter, Facebook, Wetter und Kursdaten in einem CRM System korreliert mit den Kundendaten dargestellt werden sollen, dann müssen diese für die aktuelle Auswertung ausgelesen werden. Manchmal braucht es dafür sogar eigene Dateiformatparser.



Ein weiterer Aspekt der Vorbereitung ist auch die Ablage der Daten im richtigen Datenformat, welches einfache Dateien, spezielle Dateiformate, wie auch spezielle Speichersysteme (z. B. HBase) umfasst.

Wichtig ist auch die **Partitionierung** der Daten (wenn diese nicht implizit stattfindet), zum Beispiel in HDFS. Oder des **Schlüsselentwurfs** in HBase (Schemadesign).



Hat man sich entschieden, welche Hard- und Softwarekomponenten, sowie Datenquellen und Algorithmen eingesetzt werden sollen, bleibt zuletzt die Übergabe der Lösung in den Produktionsbetrieb. Datenaufnahme, verarbeitung und -ausgabe sollten möglichst automatisiert werden. Dazu landen die Daten in einem Auffangbereich und stoßen die Verarbeitungskette(n) an.



BDE ist zusammenfassend die Aufgabe Daten innovativ und umfassend zu verarbeiten. Dazu gehört die Auswahl (oder Erstellung)

- der Hard- und Softwarekomponenten,
- der Datenquellen und Vorbereitungsschritte,
- geeigneter Verarbeitungsalgorithmen,
- der Ausgabeschnittstellen,
- sowie die Automatisierung der Prozesse für die Produktion.

Einheit 6

- Rückblick auf Einheit 5
- Diskussion: BDE Zwischenstand
- Datenpipelines

Datenpipelines



Wie besprochen braucht man für das Verarbeiten von Daten mehrere Schritte, die sich mit Teilaufgaben beschäftigen. Dazu gehört die Bereinigung von Daten, vor der eigentlichen Analyse bis hin zur Verbindung mehrerer, einzelner Verarbeitungsprozesse zu einem komplexeren Prozess.

Die **einzelnen** Schritte auf jeder dieser Ebenen können **wiederverwendet** werden.

Datenpipelines



Die Datenpipelines **teilen** sich demnach in mindestens **zwei** Klassen auf: **Makro** und **Mikro** Pipelines.

Die **Makro** Pipelines werden von den **Prozessverwaltungssystemen** (Scheduler) bestimmt. Beispiele hier sind Apache **Oozie** oder **Azkaban**.

Die **Mikro** Pipelines sind **Programmierhilfen** für die eigentliche Verarbeitung der Daten, wie beispielsweise **Crunch**, **Cascading** oder **Morphlines**.

Makro Pipelines



Die sogenannten **Scheduler** Systeme sind normalerweise **eigenständige** Prozesse, welche **komplexe** Datenverarbeitung durch das Verknüpfen von **einzelnen** Arbeitsabläufen ermöglichen.

Wir werden uns dies am Beispiel von **Oozie** anschauen. Ein anderes Beispiel ist **Azkaban**, entwickelt von LinkedIn (siehe http://azkaban.github.io/azkaban2/), oder **Luigi** von Spotify (https://github.com/spotify/luigi).

Apache Oozie



Wie erwähnt ist es in der Praxis oft wichtig mehrere Teilaufgaben zu kombinieren. Apache Oozie ist ein serverbasiertes Koordinationssystem, welches sich auf Abläufe (Workflows) spezialisiert. Diese Abläufe können über Zeitoder Datenauslöser gestartet werden, z. B. "Jede Stunde" oder "Wenn die Eingabedaten komplett vorliegen".

Abläufe werden als Graphen spezifiziert.

Oozie Abläufe



Oozie Abläufe sind eine Menge an Aktionen (Actions), z. B. MR, Hive/Pig Aufträge, welche in einem kontrollabhängige DAG (Direct Acyclic **Graph**) beschrieben sind. Kontrollabhängig für Aktionen **bedeutet**, dass eine **zweite** Aktion nur laufen kann, wenn die **erste** Aktion fertig ist. Beschrieben werden Abläufe in hPDL, eine XML basiert Process Definition Language (PDL).

Oozie Abläufe



Ein Ablauf kann sowohl Kontroll- als auch Aktionsknoten enthalten. Erstere definieren das Anfang und Ende des Ablaufs und ermöglichen den Ablauf selbst zu steuern (Entscheidung, Aufteilung und Zusammenführung).

Weiterhin kann ein Ablauf auch **parametrisiert** werden, was es erlaubt **denselben** Ablauf **mehrfach** zu verwenden, in dem man z. B. die Ein- und Ausgabe Verzeichnisse über Parameter **anpasst**.

Oozie Aktionen



Die **Aktionen** eines Ablaufs werden immer **außerhalb** von Oozie ausgeführt, normalerweise auf einem **dedizierten** Cluster. Wenn eine Aktion **fertig** ist **benachrichtigt** sie Oozie, welches dann die **nächste** Aktion starten kann.

Sie sind somit die **kleinste** Einheit an Arbeit welche Oozie unterstützt und stoßen die eigentliche **Verarbeitung** an. Oozie **liefert** Aktionen bereits **mit**, sie können aber **beliebig** durch Eigene **ergänzt** werden.

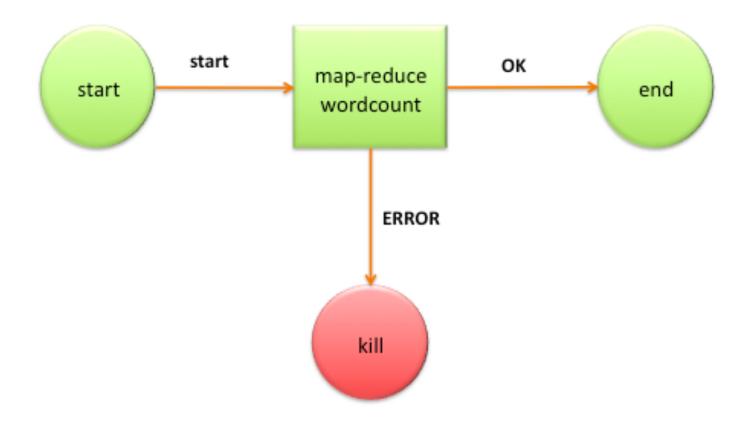
Oozie Aktionen



Die mitgelieferten Aktionen sind unter anderem

- MapReduce
- Pig und Hive
- HDFS Operationen
- SSH
- HTTP
- E-Mail
- Oozie Unterabläufe





Hinweis: Rund bedeutet Kontrollknoten, eckig sind die Aktionsknoten



Hinweise:

Es gibt immer nur **einen** einzigen **Start** und **Ende** Knoten, d. h. der Graph **muss** so definiert werden, das dies **gegeben** ist.

Alle **benutzten** Parameter müssen **gesetzt** sein über z. B. eine entsprechende Properties Datei, ansonsten **läuft** der Ablauf erst gar **nicht** an.



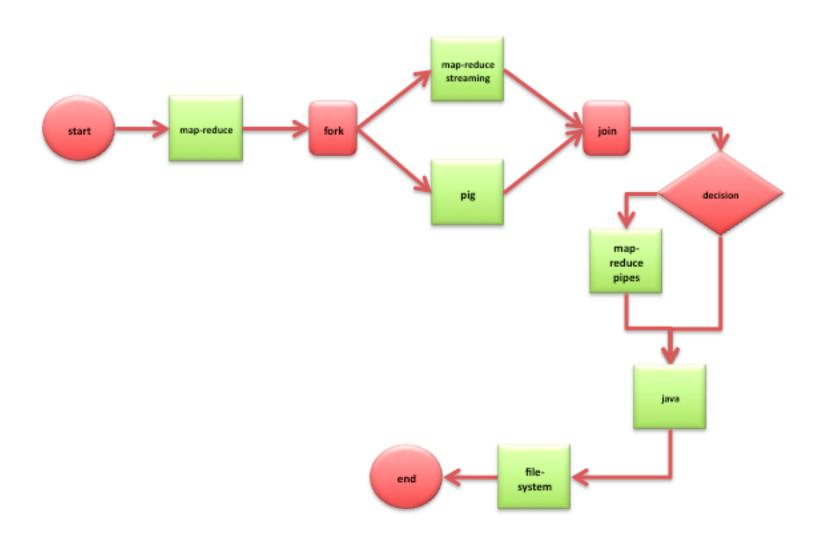
```
<workflow-app name='wordcount-wf'</pre>
xmlns="uri:oozie:workflow:0.1">
  <start to='wordcount'/>
  <action name='wordcount'>
    <map-reduce>
      <job-tracker>${jobTracker}</job-tracker>
      <name-node>$ {nameNode} </name-node>
      <configuration>
        cproperty>
          <name>mapred.mapper.class</name>
          <value>org.myorg.WordCount.Map</value>
        </property>
```



```
cproperty>
      <name>mapred.reducer.class</name>
      <value>org.myorg.WordCount.Reduce</value>
    </property>
    cproperty>
      <name>mapred.input.dir</name>
      <value>${inputDir}</value>
    </property>
    cproperty>
      <name>mapred.output.dir</name>
      <value>${outputDir}</value>
    </property>
  </configuration>
</map-reduce>
```







Ablauf Server



Oozie enthält einen **REST** basierten Server (läuft auf Apache Tomcat) mit einer **einfachen** webbasierten Oberfläche. Die Oberfläche kann nur **lesend** zugreifen, denn alle Operationen **müssen** über die Kommandozeile (**CLI**) abgeschickt werden. Die CLI ruft wiederum die **Funktionen** der REST API auf.

Der Server **führt** Abläufe aus und **überwacht** deren Status. Die Informationen legt Oozie's Server in einer relationalen Datenbank ab.

Eine Alternative stellt HUE dar (in VM enthalten).

Ablauf Anwendung



Es werden mindestens **drei** Komponenten für einen **Ablauf** benötigt:

- 1. Datei workflow.xml
 Beinhaltet die Ablauf Definition in hPDL
- 2. Bibliotheken
 Optionales Verzeichnis "lib/" für JAR und SO Dateien

3. Properties Datei

Enthält die Parameter für den Ablauf (für die workflow.xml) und muss mindestens oozie.wf.application.path setzen

Ablauf Anwendung



Beispiel für eine Properties Datei:

```
nameNode=hdfs://localhost:8020
jobTracker=localhost:8021
queueName=default
inputDir=${nameNode}/data.in
outputDir=${nameNode}/out
user.name=training
oozie.wf.application.path=\
${nameNode}/user/${user.name}/oozie/
workflow/wordcount/
```

Ablauf Anwendung



Die genannten Komponenten (Dateien) werden in ein Verzeichnis (gesetzt mit oozie.wf.application.path) in HDFS kopiert und dann über die Kommandozeile (der API) eingereicht.

Danach kann der Ablauf über die Webober-fläche oder Kommandozeile (oder eigenem Code) **überwacht** werden.

Es gibt noch weitere Optionen, welche z. B. es erlauben von Oozie aktiv benachrichtigt zu werden, wenn ein Ablauf beendet wird.

Ablauf Abschicken



Zum Abschicken eines Ablaufs:

```
$ oozie job -run -config job.properties \
    -oozie http://localhost:11000/oozie/
Workflow ID: 00123-123456-oozie-wrkf-W
```

Zum Prüfen des Status eines Ablaufs:

Ablauf Fortsetzen



Wenn Aktionen in einem Ablauf **fehlschlagen**, dann können diese **wiederholt** werden. Zuerst aber **beendet** sich der ganze Ablauf **gemäß** der DAG basierten **Definition**. Dann kann ein Ablauf entweder mit

oozie.wf.rerun.failnodes=true oder oozie.wf.rerun.skip.nodes=<k1>,... und dem Parameter - rerun wieder gestartet werden. Diese beiden Optionen sind einander ausschließend.

Oozie Koordinatoren



Ein weiteres Konzept in Oozie sind die Koordinatoren (Coordinators). Diese erlauben es Abläufe mit Zeit- oder Dateiauslösern zu starten. Dazu wird eine weitere XML Datei in dem Ablauf Verzeichnis erstellt, welches diese Bedingungen definiert.

Dies ist sinnvoll Abläufe **automatisiert** und **wiederholt** laufen zu lassen. Dadurch kann man beispielsweise auch Abläufe **verknüpfen**.

Oozie Koordinatoren



Koordinatoren sind **spezielle** Abläufe, werden aber wie die gerade gezeigten, **reinen** Abläufe genauso über die CLI abschickt.

Im Prinzip ist ein Koordinator ein dauerhaft laufender Prozess im Oozie Server, welcher je nach Definition den enthalten Ablauf anstößt.

Es gelten also die **gleichen** Kommandos für die Handhabe der Koordinatoren, wie bei den **reinen** Abläufen.

Zeitbasierte Koordinatoren



Wenn ein Ablauf zu bestimmten **Zeiten** laufen soll, kann man eine **zeitbasierte** Koordinator Definition erstellen.

Es gibt aber nur das Konzept einer **Frequenz**, **nicht** das der **zeitgenauen** Ausführung (also nicht wie z. B. **CRON**).

Alle Koordinator Definitionen müssen in einer Datei namens coordinator.xml im Hauptverzeichnis der Anwendung gespeichert werden.

Zeitbasierte Koordinatoren



Beispiel:

```
<coordinator-app name="coordinator1"</pre>
frequency="${frequency}" start="$
{startTime}" end="${endTime}"
timezone="${timezone}"
xmlns="uri:oozie:coordinator:0.1">
<action>
  <workflow>
    <app-path>${workflowPath}</app-path>
  </workflow>
</action>
</coordinator-app>
```

Zeitbasierte Koordinatoren



Genauso wie auch die eigentliche workflow.xml kann auch die coordinator.xml Datei parametrisiert werden. Zum Beispiel:

```
frequency=60 In Minuten startTime=2012-08-31T20\:20Z endTime=2013-08-31T20\:20Z timezone=GMT+0530
```

workflowPath=\${nameNode}/user/\$
{user.name}/oozie/workflow/wordcount/

Dateibasierte Koordinatoren



Wenn man in die coordinator.xml um dateibasierte Elemente erweitert, kann definiert werden, dass Oozie einen Ablauf nach Eintreffen von bestimmten Eingabedateien automatisch ausführt.

So können die **Ausgabedateien** eines Ablaufs als **Eingabe** eines weiteren dienen. Oder Daten, welche über **Flume** gespeichert werden, können nachdem ein Datei voll ist verarbeitet werden.

Dateibasierte Koordinatoren



Beispiel Definition:

```
<datasets>
  <dataset name="input1" frequency="${datasetfrequency}" \</pre>
    initial-instance="${datasetinitialinstance}" \
    timezone="${datasettimezone}">
  <uri-template>${dataseturitemplate}/${YEAR}/${MONTH}/ \
    ${DAY}/${HOUR}/${MINUTE}</uri-template>
  <done-flag> </done-flag>
  </dataset>
</datasets>
<input-events>
  <data-in name="coordInput1" dataset="input1">
    <start-instance>${inputeventstartinstance}</start-instance>
    <end-instance>${inputeventendinstance}</end-instance>
  </data-in>
</input-events>
```

Dateibasierte Koordinatoren



Beispiel Properties: In Minuten datasetfrequency=15 datasetinitialinstance=2012-08-21T15:30Z

dataseturitemplate=\${namenode}/srvs/s0001/in

datasettimezone=UTC

inputeventstartinstance=\${coord:current(0)}
inputeventendinstance=\${coord:current(0)}

workflowPath=\${nameNode}/user/\${user.name}/oozie/workflow/
wordcount/
...
inputDir= \${coord:dataIn('coordInput1')}
outputDir=\${nameNode}/out

oozie.coord.application.path=\${nameNode}/user/\${user.name}/
coordOozie/coordinatorFileBased-events>



Koordinator Abschicken

Zum Abschicken eines Koordinator Ablaufs:

```
$ oozie job -run -config job.properties \
    -oozie http://localhost:11000/oozie/
job: 00123-123456-oozie-hado-C
```

Zum Anhalten eines Koordinator Ablaufs:

```
$ oozie job -suspend 00123-123456-oozie-hado-C \
    -oozie http://localhost:11000/oozie/
```

Zum Starten eines angehaltenen Koordinator Ablaufs:

```
$ oozie job -resume 00123-123456-oozie-hado-C \
    -oozie http://localhost:11000/oozie/
```

Zum Beenden eines Koordinator Ablaufs:

```
$ oozie job -kill 00123-123456-oozie-hado-C \
   -oozie http://localhost:11000/oozie/
```

Oozie Bündel



Das **neueste** Konzept in Oozie sind die Bündel (**Bundles**), welche es erlauben **mehrere** Koordinatoren Abläufe als **Datenpipelines** zusammenzufassen. Dabei werden **Abhängigkeiten** zwischen den Abläufen definiert und diese dann von Oozie **eingehalten**.

Mikro Pipelines



Im Gegensatz zu den Makro Pipelines, sind die Mikro Pipelines eher mit der eigentlichen Datenbearbeitung beschäftigt. Sie können aber sehr wohl auch mehrere Arbeitsabläufe (Jobs) anstoßen. Der Fokus liegt aber auf dem Datenfluss und der Transformation der Tupel.

Eingabe und Ausgabe sind deshalb eben jene **Datenpaare** (oder Tupel) und die Schritte deren Verarbeitung.

Morphlines



Ein Beispiel für eine Datenpipeline ist das **Morphline** Projekt. Es ermöglicht dem Anwender **kompakte**, **wiederholbare** Befehle auf Daten anzuwenden.

Im Prinzip ähneln Morphlines den Unix Pipelines (z. B. cat text.txt | sort | uniq | wc -1) sind aber effektiver, denn sie werden in einem Prozess ausgeführt.

Morphlines



Das Projekt liefert schon viele Befehle mit, welche es erlauben bekannte Dateiformate direkt zu lesen, z. B. Log Dateien, Text, Avro, Sequence Dateien, JSON, HTML und XML.

Das Verarbeiten mit Morphlines kann in eigene Anwendungen **eingebettet** und beliebig **erweitert** werden.

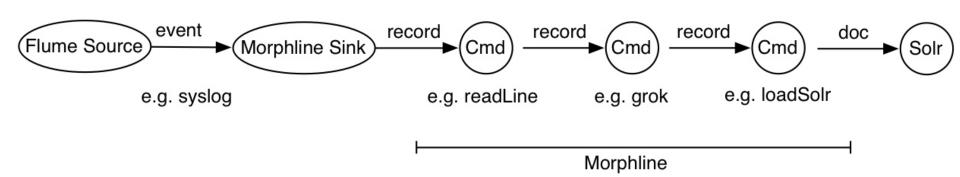
Definiert werden Morphlines im **HOCON** Format (Human-Optimized Config Object Notation).

Prozessmodell



Das Prozessmodell erlaubt es Datensätze entgegen zu nehmen, diese zu zerlegen und über eine Kette an Befehlen zu verarbeiten.

Beispiel:



Datenmodell



Das Datenmodell ist ähnlich dem MapReduce Gedanken: ein Datensatz wird in keinen, einen oder mehrere Datensätze zerlegt.

Im Unterschied zu MR ist ein Datensatz aber eine Menge an Feldern mit einem oder mehreren Werten. Also in Java ist dies:

Hashtable -> String -> Object[]

Dabei ist es egal welche Felder in welchen Datensätzen existiert (schemalos).

Binäre Lasten



Es gibt auch die Möglichkeit binäre Daten in einem Datensatz mitzuführen. Dazu existiert der feste Feldname "_attachment_body" welcher eine Java InputStream Instanz enthält (wenn gegeben).

Passend gibt es noch "_attachment_mimetype" und "_attachment_charset" welche den MIME Typ und Zeichensatznamen halten können. Dies ist der Behandlung von Anhängen in E-Mails nachempfunden.

Benutzung



Morphline liefert schon einige Anwendungen mit, z. B. einen Flume Morphline Sink oder das MapReduce Indexer Tool.

Diese führen die Morphlines innerhalb des Prozesses des Gastgebersystems aus.



Beispiel "syslog" Einträge:

```
<164>Feb 4 10:46:14 syslog sshd[607]: listening on 0.0.0.0 port 22.
```

Zu erzeugender Ausgabedatensatz:

```
priority: 164
timestamp: Feb 4 10:46:14
hostname: syslog
program: sshd
pid: 607
```

msg: listening on 0.0.0.0 port 22.
message: <164>Feb 4 10:46:14 syslog sshd[607]:
listening on 0.0.0.0 port 22.



```
grok {
         dictionaryFiles : [src/test/resources/grok-dictionaries]
         expressions : {
           message : """<%{POSINT:priority}>%{SYSLOGTIMESTAMP:timestamp} %
{SYSLOGHOST:hostname} %{DATA:program}(?:\[%{POSINT:pid}\])?: %
{GREEDYDATA:msq}"""
       convertTimestamp {
          field : timestamp
          inputFormats : ["yyyy-MM-dd'T'HH:mm:ss'Z'", ""MMM d HH:mm:ss"]
          inputTimezone : America/Los Angeles
          outputFormat : "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"
          outputTimezone : UTC
```



```
sanitizeUnknownSolrFields {
  # Location from which to fetch Solr schema
  solrLocator : {
   collection: collection # Name of solr collection
   zkHost : "127.0.0.1:2181/solr" # ZooKeeper ensemble
logInfo { format : "output record: {}", args : ["@{}"] } }
loadSolr {
  solrLocator : {
   collection: collection1 # Name of solr collection
    zkHost: "127.0.0.1:2181/solr" # ZooKeeper ensemble
```



Beispiel "log4j" Einträge:

```
juil. 25, 2012 10:49:40 AM hudson.triggers.SafeTimerTask run ok
juil. 25, 2012 10:49:46 AM hudson.triggers.SafeTimerTask run failed
com.amazonaws.AmazonClientException: Unable to calculate a request signature
    at com.amazonaws.auth.AbstractAWSSigner.signAndBase64Encode(AbstractAWSSigner.java:71)
    at java.util.TimerThread.run(Timer.java:505)
Caused by: com.amazonaws.AmazonClientException: Unable to calculate a request signature
    at com.amazonaws.auth.AbstractAWSSigner.sign(AbstractAWSSigner.java:90)
    at com.amazonaws.auth.AbstractAWSSigner.signAndBase64Encode(AbstractAWSSigner.java:68)
    ... 14 more
Caused by: java.lang.IllegalArgumentException: Empty key
    at javax.crypto.spec.SecretKeySpec.<init>(SecretKeySpec.java:96)
    at com.amazonaws.auth.AbstractAWSSigner.sign(AbstractAWSSigner.java:87)
    ... 15 more
juil. 25, 2012 10:49:54 AM hudson.slaves.SlaveComputer tryReconnect
```



Beispiel "log4j" Einträge:

```
juil. 25, 2012 10:49:40 AM hudson.triggers.SafeTimerTask run ok
juil. 25, 2012 10:49:46 AM hudson.triggers.SafeTimerTask run failed
com.amazonaws.AmazonClientException: Unable to calculate a request signature
  at com.amazonaws.auth.AbstractAWSSigner.signAndBase64Encode(AbstractAWSSigner.java:71)
  at java.util.TimerThread.run(Timer.java:505)
Caused by: com.amazonaws.AmazonClientException: Unable to calculate a request signature
  at com.amazonaws.auth.AbstractAWSSigner.sign(AbstractAWSSigner.java:90)
  at com.amazonaws.auth.AbstractAWSSigner.signAndBase64Encode(AbstractAWSSigner.java:68)
  ... 14 more
Caused by: java.lang.IllegalArgumentException: Empty key
  at javax.crypto.spec.SecretKeySpec.<init>(SecretKeySpec.java:96)
  at com.amazonaws.auth.AbstractAWSSigner.sign(AbstractAWSSigner.java:87)
  ... 15 more
juil. 25, 2012 10:49:54 AM hudson.slaves.SlaveComputer tryReconnect
```

Morphlines



```
morphlines : [{
  id : morphline1
  importCommands : ["com.cloudera.**", "org.apache.solr.**"]
  commands : [{
    readMultiLine {
      regex : "(^.+Exception: .+)|(^\\s+at .+)|(^\\s+... \\d+
more) | (^\\s*Caused by:.+)"
      what : previous
      charset: UTF-8
  { logDebug { format : "output record: {}", args : ["@{}"] } }
  { loadSolr {}
} ]
```

Eingebettete Ausführung



```
/** Usage: java ... <morphlines.conf> <dataFile1> ... <dataFileN> */
public static void main(String[] args) {
  // compile morphlines.conf file on the fly
  File configFile = new File(args[0]);
  MorphlineContext context = new MorphlineContext.Builder().build();
  Command morphline = new Compiler().compile(
    configFile, null, context, null);
  // process each input data file
  Notifications.notifyBeginTransaction(morphline);
  for (int i = 1; i < args.length; <math>i++) {
    InputStream in = new FileInputStream(new File(args[i]));
    Record record = new Record();
    record.put(Fields.ATTACHMENT BODY, in);
    morphline.process (record);
    in.close();
  Notifications.notifyCommitTransaction(morphline);
```



Nachdem betrachten der einzelnen Werkzeuge zur Datenverarbeitung und dem Bilden von Verarbeitungsketten (Pipelines), bleibt als weiteres Thema die Organisation von Daten.

Speziell im Mandantenbetrieb ist es wichtig Daten geordnet und strukturiert anzulegen, damit Fachabteilungen ihre und die Daten anderen Abteilungen finden und nutzen können. Dies ist die Informationsarchitektur.



Für Lösungen basierend auf Hadoop ist dies mit Diensten (Services) abdeckbar. Dazu wird jeder Anwendungsfall in Benutzergruppen abgebildet, welche es für normaler Nutzer und Administratoren gibt. In HDFS z. B. werden dann die Dateien mit den entsprechenden Rechten in speziellen Verzeichnissen pro Dienst oder Anwendergruppe abgelegt.

Beispiele: /srvs/s1/ oder /system/etl/sales



Unterhalb der Dienst-/Gruppenebene werden dann Verzeichnisse für eingehende (incoming), ausgehende (complete), fehlerhafte (failed) und gerade bearbeitete Daten (working) abgebildet. Im Arbeitsverzeichnis (working) wird pro Verarbeitungslauf ein Verzeichnis mit Zeitstempel (oder z. B. Oozie Job ID) angelegt. Damit können mehrere Abläufe parallel laufen **ohne** sich zu überschneiden.



Komplettes Beispiel:

```
/system
/system/etl/<group>/<process>
  /incoming
  /complete
  /failed
  /working
     /<epoch idx>
/incoming
/complete
/system/data/<dataset>
```



Dateien in den Verzeichnissen werden dann den entsprechenden Gruppen **zugeordnet**, z. B. s1admin, s1user, s2admin, s2user,...

Wenn man **Ergebnisse** des Dienst #1 (s1) den Nutzern von Dienst #2 (s2) **zugänglich** machen möchte so müssen lediglich die passenden Benutzer der Gruppe s2 mit der **zusätzlichen** Gruppe s1user versehen werden.



Die Benutzergruppen können weiterhin für die Rechtevergabe in den Verarbeitungsschlangen (Queues) verwendet werden. Damit kann einer Gruppe von Benutzern (oder einem automatisierten Dienst) genau zugeordnet werden, wie viele Ressourcen sie benutzen oder ob sie überhaupt Jobs laufen lassen dürfen.

Fazit: Hadoop selbst setzt **keine** Regeln, die Informationsarchitektur **muss** dies regeln.

Einheit 6



An dieser Stelle endet die sechste Einheit, welche die Datenpipelines vorstellt und am Beispiel von Oozie und Morphlines vertieft.

In der nächsten Einheit befassen wir uns mit den abschließenden Fragen des Systemdesigns: Wie kombiniert man, zum Beispiel, Batch und Echtzeit Anwendungsfälle, oder wie bindet man die Ergebnisse in BI Lösungen ein?

Bis bald!



Übung 6

Ziele:

- Datenpipeline mit Oozie erstellen
- Datenpipeline mit Morphlines erstellen

Übung 6



Code:

https://github.com/larsgeorge/fh-muenster-bde-lesson-6

Quellen



- Oozie
 - Projekt: http://oozie.apache.org/
- Morphlines
 - Kite SDK:
 http://kitesdk.org/docs/current/kite-morphlines/
 index.html
 - Blog Post:
 http://www.cloudera.com/content/cloudera-content/cloud